# Clasificación ordinal del desgaste de brocas en taladrado CNC mediante análisis acústico: sensibilidad al umbral de etiquetado

Jorge Enrique Meneses Flórez[1], Nicolás Orejarena Osorio[2], Oscar Iván Ayala Ortiz[3]

Escuela de Ingeniería Mecánica, Universidad Industrial de Santander, La Universidad, Bucaramanga, Colombia[1,2,3]

E-mail: jmeneses@uis.edu.co[1], norejarena@correo.uts.edu.co[2], ayalaortizoscarivan@gmail.com[3]

## Resumen

Se presenta un sistema de clasificación ordinal del desgaste de brocas helicoidales en taladrado CNC de acero AISI 4140, orientado al mantenimiento predictivo y basado exclusivamente en señales acústicas capturadas con micrófonos de bajo costo. Se emplea el método de descomposición ordinal de Frank y Hall con máquinas de vectores de soporte (SVM) y bosques aleatorios (RF), utilizando 10 *features* acústicas seleccionadas estadísticamente. La contribución central es un análisis de sensibilidad al umbral de etiquetado, barriendo el porcentaje de vida útil que define la clase "desgastado" desde el 60 % hasta el 97 %. Los resultados muestran que las *features* acústicas *hand-crafted* detectan eficazmente el fallo catastrófico (umbral $\geq 97\,\%$: $F_1$ macro = 0,46, exactitud adyacente = 98,6 %), pero su capacidad disminuye para desgaste progresivo temprano (umbral $\geq 60\,\%$: $F_1$ macro = 0,30, exactitud adyacente = 83,4 %). Un hallazgo clave es que la exactitud adyacente permanece superior al 83 % en todo el rango de umbrales, indicando que los errores de clasificación nunca exceden un paso ordinal. Mediante una etapa de refinamiento que incorpora ingeniería de *features* derivadas, optimización de hiperparámetros (kernel lineal, $C = 5$, pesos de clase asimétricos) y calibración de umbrales de decisión, la exactitud adyacente de la SVM al umbral del 75 % alcanza 98,5 % y la exactitud exacta 60,2 %, superando a la configuración base (85,9 % y 50,3 %, respectivamente). El análisis de generalización cruzada entre siete experimentos independientes revela que el tipo de micrófono es la principal fuente de *domain shift*. La reducción de ruido espectral (*spectral gating*) mejora la exactitud adyacente en test de 84,7 % a 90,1 % y reduce el *domain shift* entre tipos de micrófono ($F_1$: 0,18 $\rightarrow$ 0,33; exactitud: 23 % $\rightarrow$ 59 % en validación con micrófono dinámico). Estos resultados delimitan el alcance operacional del monitoreo acústico pasivo con *features hand-crafted*, con implicaciones directas para la implementación en sistemas de monitoreo en línea de bajo costo computacional, y motivan el uso de representaciones espectrales aprendidas para la detección de desgaste gradual.

**Palabras clave:** desgaste de herramientas, taladrado CNC, clasificación ordinal, análisis acústico, SVM, sensibilidad al umbral, mantenimiento predictivo, Industria 4.0.

## Abstract

An ordinal classification system for drill bit wear in CNC drilling of AISI 4140 steel is presented, aimed at predictive maintenance and based exclusively on acoustic signals captured with low-cost microphones. The Frank and Hall ordinal decomposition method is employed with support vector machines (SVM) and random forests (RF), using 10 statistically selected acoustic features. The central contribution is a labeling threshold sensitivity analysis, sweeping the tool life percentage that defines the "worn" class from 60 % to 97 %. Results show that hand-crafted acoustic features effectively detect catastrophic failure (threshold $\geq 97\,\%$: macro $F_1$ = 0.46, adjacent accuracy = 98.6 %), but their discriminative power decreases for early progressive wear (threshold $\geq 60\,\%$: macro $F_1$ = 0.30, adjacent accuracy = 83.4 %). A key finding is that adjacent accuracy remains above 83 % across all thresholds, indicating that classification errors never exceed one ordinal step. A refinement stage incorporating derived feature engineering, hyperparameter optimization (linear kernel, $C = 5$, asymmetric class weights), and decision threshold calibration raises adjacent accuracy at the 75 % threshold to 98.5 % and exact accuracy to 60.2 %, surpassing the baseline configuration (85.9 % and 50.3 %, respectively). Cross-experiment generalization analysis across seven independent experiments reveals that microphone type is the primary source of domain shift. Spectral gating noise reduction improves test adjacent accuracy from 84.7 % to 90.1 % and reduces cross-microphone domain shift (validation $F_1$: 0.18 $\rightarrow$ 0.33; accuracy: 23 % $\rightarrow$ 59 %).

**Keywords:** tool wear, CNC drilling, ordinal classification, acoustic analysis, SVM, threshold sensitivity, predictive maintenance, Industry 4.0.

# 1. Introducción

El monitoreo de la condición de herramientas de corte es un componente esencial en la manufactura moderna, donde la detección oportuna del desgaste permite reducir costos de producción, mejorar la calidad dimensional de las piezas y prevenir fallas catastróficas que comprometan la integridad de la máquina y la seguridad del operario [1]. En operaciones de taladrado CNC, el desgaste progresivo del filo de corte modifica las fuerzas de corte, las vibraciones mecánicas y la emisión acústica del proceso [2].

El enfoque acústico para el monitoreo de herramientas ha ganado atención por ser no invasivo, de bajo costo y fácil de integrar en entornos industriales existentes [3, 4, 10]. Si bien los enfoques basados en aprendizaje profundo (*deep learning*) han demostrado alta precisión en tareas de clasificación de señales, su costo computacional limita su despliegue en sistemas embebidos de borde (*edge computing*) propios de la manufactura inteligente [1]. En contraste, los modelos basados en *features* acústicas *hand-crafted* con clasificadores ligeros (SVM, RF) permiten inferencia en tiempo real con recursos computacionales mínimos, lo que los hace particularmente adecuados para aplicaciones de mantenimiento predictivo en el contexto de la Industria 4.0.

Sin embargo, la mayoría de los trabajos previos abordan el problema como clasificación binaria (nueva vs. desgastada) o categórica sin considerar la naturaleza progresiva del desgaste [5]. Esta simplificación ignora información ordinal valiosa: confundir una herramienta nueva con una moderadamente desgastada tiene consecuencias operacionales distintas a confundirla con una herramienta en fallo.

Un segundo problema frecuente es la definición del umbral que separa las clases de desgaste. La mayoría de los estudios utilizan un umbral fijo (típicamente basado en el criterio de flanco VB según ISO 8688 o ISO 3685 [6]) sin explorar la sensibilidad de los resultados a esta elección. En escenarios donde no se dispone de medición directa de VB — como cuando se utilizan exclusivamente señales acústicas — el umbral se define sobre el porcentaje de vida útil consumida, lo que introduce una decisión metodológica cuyo impacto rara vez se cuantifica.

El presente trabajo aborda ambas limitaciones. Se formula el problema como clasificación ordinal, es decir, una tarea en la que las clases tienen un orden natural entre sí y, por tanto, no se consideran categorías totalmente independientes. En este caso se clasifican en tres clases (sin desgaste, medianamente desgastado,desgastado) utilizando el método de Frank y Hall [7] con SVM y RF. La contribución central es la identificacion del porcentaje de vida util correspondiente a la zona desgaste. Para ello se iteraron diferetes rangos de etiquetado hasta encontrar la precisión ajustada, la cual ajusta los problemas de desbalance debido a que no se tiene la misma cantidad de datos en cada estado. De esta manera se obtuvo que la definición de desgastado corresponde de un 60 % hasta el 98.5 % de la vida útil. Este barrido permite mapear los límites operacionales del monitoreo acústico pasivo con *features hand-crafted* y establecer recomendaciones sobre qué umbrales son viables para el estado medianamente desgastado versus detección del estado desgastado.

Las contribuciones específicas son: (1) formulación ordinal del desgaste de brocas con métricas apropiadas (MAE ordinal, exactitud adyacente); (2) análisis de sensibilidad al umbral con curva completa de 9 umbrales; (3) evaluación de generalización cruzada entre 7 experimentos independientes; (4) estudio de ablación de *features* que revela que un subconjunto de 7 *features* supera al conjunto completo de 10; (5) evaluación del impacto de la reducción de ruido espectral como preprocesamiento para mitigar el *domain shift* entre tipos de micrófono.

# 2. Materiales y métodos

## 2.1. Configuración experimental

Los ensayos de taladrado se realizaron en un centro de mecanizado CNC Leadwell V-20 (recorridos: $510 \times 350 \times 400$ mm, velocidad máxima del husillo: 8000 rpm). El material de trabajo fue acero AISI 4140 bonificado (28–32 HRC), en discos de $6'' \times 2''$ sujetos con copa periférica. Se utilizaron brocas helicoidales Dormer A100 de 6 mm y 8 mm de diámetro, con trayectoria en espiral o lineal según el ensayo. Todos los ensayos emplearon refrigerante (taladrina) y agujeros ciegos de 25 mm de profundidad.

Se realizaron siete ensayos independientes (E1–E7), cuyas condiciones se resumen en la Tabla 1. Se usaron 3 diferentes trayectorias, lineal, expiral y mixto. Los ensayos E1–E4 se condujeron hasta falla completa de la broca (tres clases de desgaste), mientras que E5–E7 registraron desgaste progresivo sin alcanzar falla (dos clases).

Tabla 1: Condiciones experimentales de los siete ensayos.

| Exp. | ∅ (mm) | G-code | Micrófono | Tipo | $n$ |
|---|---|---|---|---|---|
| E1 | 8 | mixto | dinámico | Hasta falla | 84 |
| E2 | 8 | espiral | dinámico | Hasta falla | 128 |
| E3 | 6 | lineal | condensador | Hasta falla | 583 |
| E4 | 6 | espiral | condensador | Hasta falla | 1194 |
| E5 | 8 | lineal | condensador | Progresivo | 234 |
| E6 | 8 | lineal | condensador | Progresivo | 234 |
| E7 | 6 | espiral | condensador | Progresivo | 148 |
| Total | | | | | 2565(definir n de la tabla) |

Los parámetros de corte se calcularon según las recomendaciones del fabricante: velocidad de corte $V_c = 20\,\mathrm{m/min}$, avance $f = 0{,}109\,\mathrm{mm/rev}$ (6 mm) y $f = 0{,}138\,\mathrm{mm/rev}$ (8 mm), resultando en velocidades del husillo de 1061 rpm y 796 rpm, respectivamente.

## 2.2. Sistema de adquisición de datos

La adquisición se realizó con un chasis NI cDAQ-9174 equipado con un módulo NI-9234 (4 canales, 51,2 kS/s, 24 bits, filtro *anti-aliasing* integrado). Se emplearon dos micrófonos en configuraciones alternadas según el ensayo [4]:

- **M1**: TXL 235 TOPP AUDIO (dinámico), utilizado en E1 y E2.
- **M2**: PG81 SHURE (condensador, cardioide), utilizado en E3–E7.

Esta asignación implica que el tipo de micrófono constituye una covariable confundida con el diseño experimental, aspecto que se analiza en la Sección 4.

Las señales se adquirieron a una frecuencia de muestreo de $f_s = 51{,}2\,\mathrm{kS/s}$ (ancho de banda útil hasta 25,6 kHz), en formato *Technical Data Management Streaming* (TDMS), y se convirtieron a WAV PCM de 16 bits sin compresión para preservar la integridad de los transitorios acústicos [8].

## 2.3. Preprocesamiento: reducción de ruido espectral

Para evaluar el impacto del ruido de fondo en la clasificación, se implementó un *pipeline* de programación para la reducción del ruido basado en el método de filtrado *spectral gating* estacionario. Se construyó un perfil de ruido combinó grabaciones de referencia, tales como ruido del husillo sin taladrado (≈180 min disponibles), husillo con refrigerante (≈46 min) y ambiente del laboratorio (≈48 min), todas adquiridas con el mismo sistema NI-9234 a 51,2 kS/s segmentadas cada 120s para efectos de entrenamiento.

El filtrado se aplicó a los 2635 archivos originales WAV mediante la librería `noisereduce` [14] con los parámetros: modo estacionario (`stationary=True`), proporción de atenuación $\alpha = 0{,}85$, $n_{\mathrm{FFT}} = 2048$ y la señal de referencia como perfil de ruido anteriormente combinado. La señal filtrada conserva sus niveles relativos (sin normalización de pico) para no alterar las *features* (características) dependientes de energía. De estos se reextrajeron las mismas 7 *features* (características) con mas influencia en los resultados de predicción a la hora de entrenar los modelos empleando un estudio de ablación.

## 2.4. Extracción de *features* (características) acústicas del modelo que predice

Se extrajeron 21 *features* ancla que cubren tres dominios físicos: timbre (centroide espectral, MFCC, planitud, contraste, entropía, chroma, ratio armónico/percusivo), energía (RMS, factor de cresta, energía Mel y wavelet) y temporal (duración, tasa de *onsets*, ZCR). A partir de un proceso de selección multi-criterio — bootstrap de estabilidad en top-$N$, ANOVA/Kruskal-Wallis, análisis de no-redundancia e información mutua — se seleccionaron las 10 *features* de la Tabla 2.

Tabla 2: *Features* acústicas seleccionadas (línea base).

| # | Feature | Dominio | Interpretación física |
|---|---|---|---|
| 1 | spectral_contrast | Timbre | Diferencia picos/valles espectrales |
| 2 | crest_factor | Energía | Ratio pico/RMS (impulsividad) |
| 3 | chroma_std | Timbre | Variabilidad cromática |
| 4 | zcr | Temporal | Cruces por cero (ruido de banda ancha) |
| 5 | spectral_entropy | Timbre | Desorden espectral |
| 6 | centroid_mean | Timbre | Centro de masa espectral |
| 7 | harmonic_perc. | Timbre | Ratio armónico/percusivo |
| 8 | onset_rate | Temporal | Frecuencia de transitorios |
| 9 | spectral_flatness | Timbre | Tonalidad vs. ruido |
| 10 | duration_s | Temporal | Duración del ciclo |

## 2.5. Estrategia de etiquetado con barrido de umbrales

Al no disponer de mediciones directas de desgaste de flanco (VB), las etiquetas se asignan según el porcentaje de vida útil consumida, definido como la razón entre el número de agujero actual y el número total de agujeros realizados con cada broca. Se definen tres clases ordinales:

$$y_i = \begin{cases} \text{sin desgaste} & \text{si } p_i \le \tau_{\text{sin}} \\ \text{med. desgastado} & \text{si } \tau_{\text{sin}} < p_i < \tau_{\text{des}} \\ \text{desgastado} & \text{si } p_i \ge \tau_{\text{des}} \end{cases} \tag{1}$$

donde $p_i = h_i / h_{\text{máx}}$ es la fracción de vida útil consumida para la muestra $i$, $\tau_{\text{sin}} = 0{,}15$ (fijo) y $\tau_{\text{des}}$ es el umbral que se varía. Los ensayos E5–E7 (progresivos, sin falla) conservan sus etiquetas originales, asignadas mediante análisis de tendencia de *features* acústicas (RMS, centroide, ZCR) a lo largo del ensayo, siguiendo el enfoque correlacional de Meneses y Peña [10].

La contribución central de este trabajo es barrer $\tau_{\text{des}}$ en nueve valores: 60 %, 65 %, 70 %, 75 %, 80 %, 85 %, 90 %, 95 % y 97 %. Para cada umbral se reetiqueta el dataset completo, se reentrenan los modelos y se evalúa en el conjunto de test, permitiendo construir una curva de sensibilidad que mapea la capacidad discriminativa de las *features* acústicas en función del grado de desgaste.

## 2.6. Clasificación ordinal: método de Frank y Hall

Se emplea el método de Frank y Hall [7], que descompone un problema ordinal de $K$ clases en $K-1$ clasificadores binarios. Para tres clases ($k \in \{0,1,2\}$, donde 0 = sin desgaste, 1 = medianamente desgastado, 2 = desgastado), se entrenan dos clasificadores:

$$C_1 : P(y \geq 1) \quad \text{“¿Hay algún desgaste?”} \tag{2}$$
$$C_2 : P(y \geq 2) \quad \text{“¿El desgaste es severo?”} \tag{3}$$

Las probabilidades se combinan con restricción de monotonicidad ($\hat{P}_2 \leq \hat{P}_1$) para obtener la distribución ordinal:

$$P(\text{sin}) = 1 - \hat{P}_1 \tag{4}$$
$$P(\text{med}) = \hat{P}_1 - \hat{P}_2 \tag{5}$$
$$P(\text{des}) = \hat{P}_2 \tag{6}$$

y la clase predicha es $\hat{y} = \arg\text{máx}_k P(k)$.

Cada clasificador binario $C_j$ es una SVM con kernel RBF, optimizada mediante *GridSearchCV* ($C \in \{1, 10\}$, $\gamma \in \{\text{scale}, 0{,}1\}$) con validación cruzada *StratifiedGroupKFold* de 3 particiones, agrupando por experimento para evitar fuga de información entre ensayos del mismo grupo experimental. Esta estrategia garantiza que las muestras del mismo experimento nunca aparezcan simultáneamente en entrenamiento y validación interna [9]. Se utiliza `class_weight='balanced'` para compensar el desbalance de clases. Como comparación, se entrena un RF ordinal con la misma descomposición de Frank y Hall (200 árboles, `class_weight='balanced'`).

Adicionalmente, se realizó una etapa de refinamiento que incluyó: (i) 7 *features* derivadas por combinación de las originales (ratios espectrales, indicadores de estabilidad tonal y energía), (ii) búsqueda de hiperparámetros extendida sobre 30 configuraciones (kernels lineal y RBF, $C \in \{0{,}5;\ 1;\ 5;\ 10;\ 50\}$, selección de $k \in \{10;\ 15;\ 20;\ \text{todas}\}$ *features* por información mutua, pesos de clase asimétricos), y (iii) calibración de los umbrales de decisión $t_1$ y $t_2$ del clasificador ordinal (barrido en $[0{,}15;\ 0{,}70]$ con paso de 0,05), optimizando un *score* compuesto: $0{,}4 \times \text{adj. acc.} + 0{,}3 \times \text{bal. acc.} + 0{,}3 \times \text{exact. acc.}$

## 2.7. Diseño experimental y métricas

La partición del dataset respeta la independencia experimental:

- **Test**: E3 completo (583 muestras, 6 mm, condensador).
- **Validación**: E2 completo (128 muestras, 8 mm, dinámico).
- **Entrenamiento**: E1 + E4 + E5 + E6 + E7 (2224 muestras, incluyendo augmentados acústicos).

Se seleccionó E3 como test por ser el ensayo más extenso con falla completa (583 muestras, tres clases), y E2 como validación por presentar el mayor *domain shift* (micrófono dinámico, 8 mm), permitiendo evaluar robustez. La augmentación acústica del entrenamiento incluyó *time stretching*, adición de ruido gaussiano y desplazamiento de *pitch*, aplicadas exclusivamente a muestras de la clase “desgastado” para mitigar el desbalance (90 muestras augmentadas). Ningún dato augmentado aparece en validación ni test, y los augmentados derivados de E3 se excluyen del entrenamiento para evitar fuga de información.

Las métricas reportadas incluyen:

- **Macro $F_1$**: promedio no ponderado del $F_1$ por clase.
- **Exactitud adyacente**: fracción de predicciones con error $\leq 1$ paso ordinal (ec. 7).
- **MAE ordinal**: error absoluto medio entre clases predichas y verdaderas (ec. 8).
- **Exactitud exacta**: fracción de predicciones correctas.

$$\text{Adj. Acc.} = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}[|\hat{y}_i - y_i| \leq 1] \tag{7}$$
$$\text{MAE}_{\text{ord}} = \frac{1}{n} \sum_{i=1}^{n} |\hat{y}_i - y_i| \tag{8}$$

Los intervalos de confianza al 95 % se estiman mediante *bootstrap* con 1000 remuestreos del conjunto de test.

# 3. Resultados

## 3.1. Análisis exploratorio

La Fig. 1 muestra la proyección PCA bidimensional del conjunto de test (E3) sobre las 10 *features* seleccionadas. Los dos primeros componentes principales explican el 67,9 % de la varianza (PC1: 41,8 %, PC2: 26,1 %). Se observa que las muestras de clase “sin desgaste” se separan parcialmente del grupo principal, mientras que “medianamente desgastado” y “desgastado” presentan solapamiento considerable, consistente con la frontera difusa entre desgaste progresivo.

La distribución de clases por experimento (Fig. 2) evidencia que E4 domina el dataset (1194 muestras) y que los ensayos progresivos (E5–E7) carecen de clase “desgastado”, lo que limita su contribución al entrenamiento del clasificador $C_2$.

El ranking de información mutua (Fig. 3) para el conjunto completo de 26 *features* muestra que las *features* de variabilidad espectral (`spectral_bandwidth_std`, `rolloff_std`) ganan relevancia con umbrales bajos (desgaste gradual), mientras que `spectral_contrast_mean` domina a umbral alto (97 %, fallo catastrófico). Entre las 10 *features* del baseline, `spectral_contrast_mean` mantiene la mayor información mutua con la etiqueta de desgaste en todos los umbrales, seguida de `centroid_mean` y `zcr`.

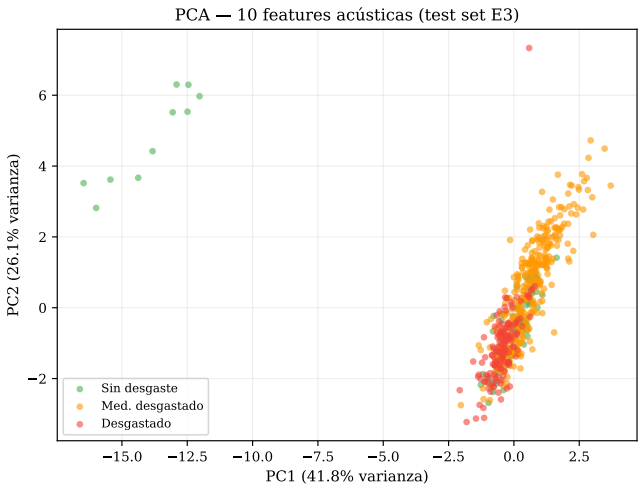


Figura 1: Proyección PCA bidimensional del test set E3 (10 *features*, reetiquetado al 75 %).

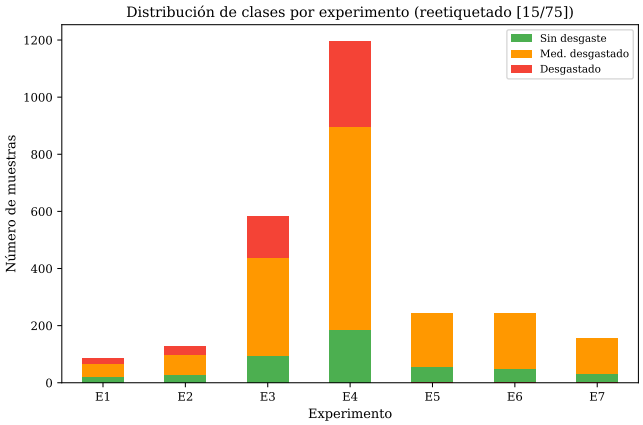


Figura 2: Distribución de clases por experimento (reetiquetado $\tau_{\text{des}} = 75\,\%$).

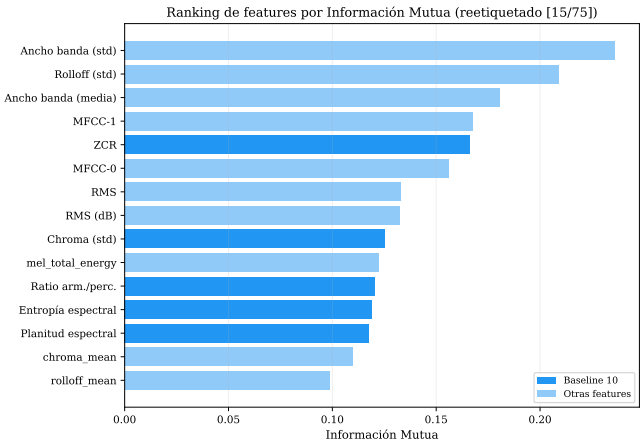


Figura 3: Ranking de *features* por información mutua (reetiquetado al 75 %).

## 3.2. Curva de sensibilidad al umbral

La Fig. 4 y la Tabla 3 presentan el resultado principal del trabajo: la curva de sensibilidad al umbral de etiquetado.

Se identifican tres hallazgos principales:

**1) El $F_1$ macro crece con el umbral.** La SVM pasa de $F_1 = 0{,}30$ (60 %) a $F_1 = 0{,}46$ (97 %), un incremento del 53 %. Esto confirma que las *features* acústicas *hand-crafted* detectan más fácilmente el fallo catastrófico (chirping, chatter) que el desgaste gradual de flanco, cuya firma acústica es más sutil.

**2) La exactitud adyacente permanece alta.** Incluso al umbral más exigente (60 %), la exactitud adyacente de la SVM es 83,4 % y la del RF 90,9 %. A partir del 85 %, supera el 92 % (SVM) y 96 % (RF). Esto significa que *los errores de clasificación nunca saltan dos clases*: un error típico confunde "medianamente desgastado" con "desgastado" o viceversa, pero nunca "sin desgaste" con "desgastado".

**3) El RF supera a la SVM base en casi todos los umbrales.** La ventaja del RF es consistente en exactitud adyacente (+4 a +8 puntos porcentuales) y $F_1$ macro (+0,02 a +0,09), excepto a 97 % donde la SVM logra $F_1 = 0{,}46$ versus $F_1 = 0{,}44$ del RF. Esta superioridad se explica porque el RF, al promediar múltiples árboles de decisión con submuestreo aleatorio, es inherentemente más robusto al desbalance de clases y a la variabilidad del espacio de *features*, mientras que la SVM RBF con umbrales de decisión por defecto tiende a concentrar sus predicciones en la clase mayoritaria. Sin embargo, tras la etapa de refinamiento (Sección 3.7), la SVM optimizada alcanza una exactitud adyacente de 98,5 % al umbral del 75 %, superando al RF base (93,3 %) en este punto de operación.

Los intervalos de confianza *bootstrap* (95 %, 1000 remuestreos) para el modelo SVM entrenado con etiquetas originales (equivalente al umbral 97 % con 4 muestras de desgaste en test) son: $F_1 = 0{,}54$ [0,38; 0,75], exactitud = 94,0 % [92,1; 95,7], exactitud adyacente = 100 %, MAE = 0,06 [0,04; 0,08]. El intervalo amplio del $F_1$ refleja el soporte estadístico limitado de la clase "desgastado" a este umbral. Para el reetiquetado al 75 % (144 muestras de desgaste), el IC se estrecha: $F_1 = 0{,}35$ [0,32; 0,39].

## 3.3. Análisis por clase

El panel (c) de la Fig. 4 descompone el $F_1$ por clase para la SVM. La clase "medianamente desgastado" mantiene $F_1 > 0{,}55$ en todos los umbrales gracias a su prevalencia en el test set. La clase "sin desgaste" es estable pero baja ($F_1 \approx 0{,}27$–$0{,}31$), sugiriendo que el modelo confunde muestras iniciales con desgaste moderado. La clase "desgastado" es la más sensible al umbral: su $F_1$ crece de 0,04 (60 %) a 0,37 (97 %), reflejando que solo el fallo catastrófico produce una firma acústica claramente distinguible.

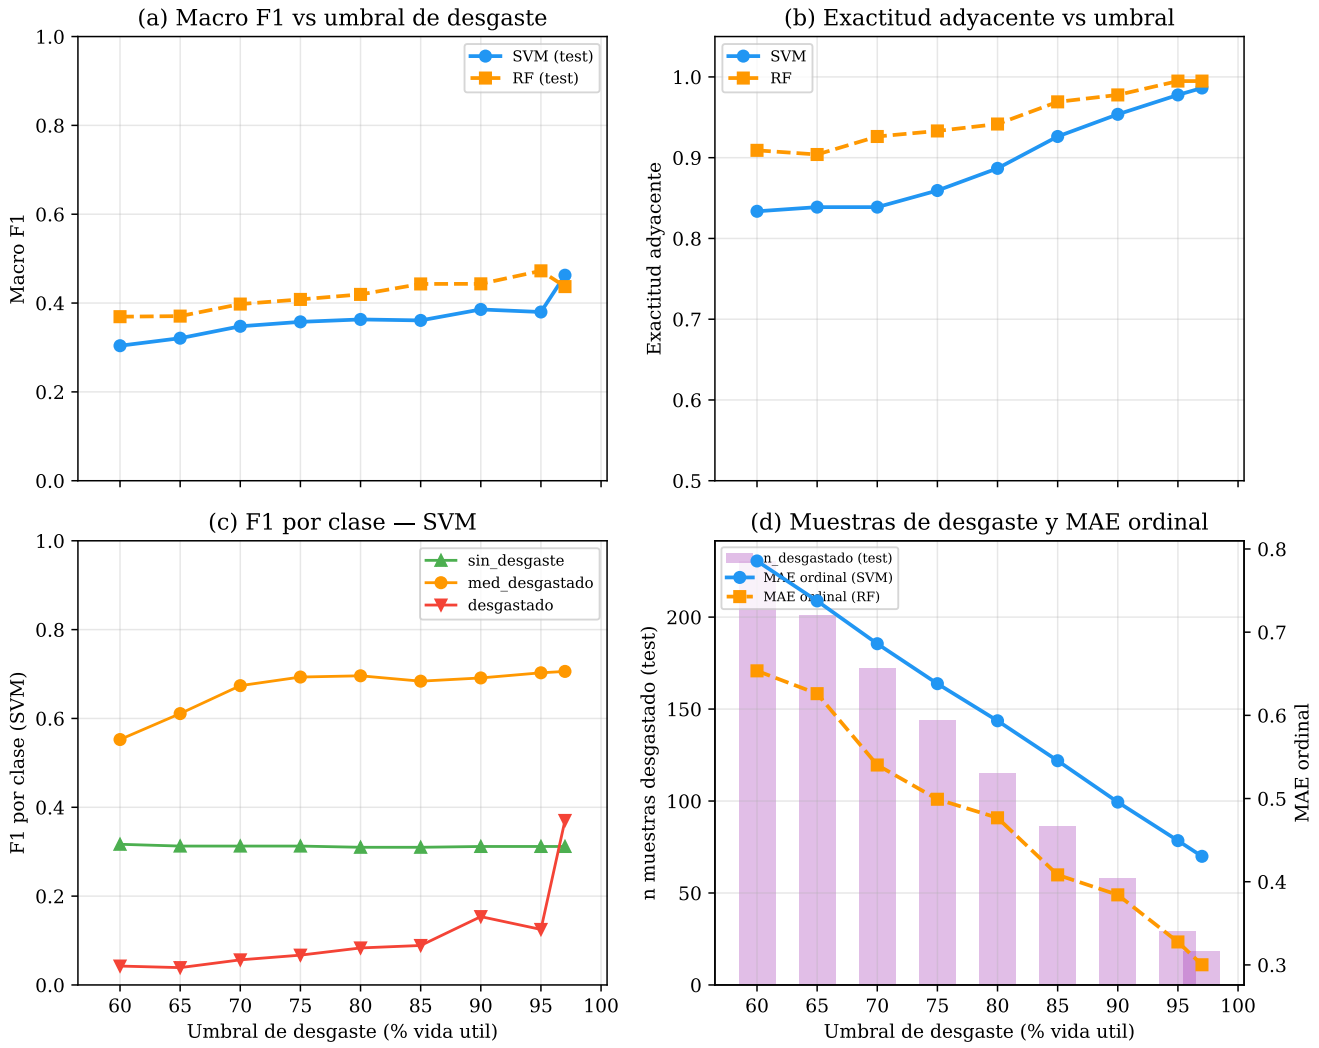


Figura 4: Sensibilidad al umbral de etiquetado. (a) Macro $F_1$ vs. umbral. (b) Exactitud adyacente vs. umbral. (c) $F_1$ por clase (SVM). (d) Número de muestras de desgaste en test y MAE ordinal.

Tabla 3: Métricas de clasificación ordinal por umbral de etiquetado ($\tau_{\text{sin}} = 15\,\%$, test = E3).

| $\tau_{\text{des}}$ (%) | $n_{\text{des}}^{\text{test}}$ | SVM ordinal | | | | RF ordinal | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | $F_1$ | Acc. | Adj. | MAE | $F_1$ | Acc. | Adj. | MAE |
| 60 | 230 | 0,304 | 0,381 | 0,834 | 0,786 | 0,369 | 0,437 | 0,909 | 0,654 |
| 65 | 201 | 0,321 | 0,424 | 0,839 | 0,738 | 0,371 | 0,470 | 0,904 | 0,626 |
| 70 | 172 | 0,348 | 0,475 | 0,839 | 0,686 | 0,398 | 0,533 | 0,926 | 0,540 |
| 75 | 144 | 0,358 | 0,503 | 0,859 | 0,638 | 0,408 | 0,568 | 0,933 | 0,499 |
| 80 | 115 | 0,363 | 0,520 | 0,887 | 0,593 | 0,419 | 0,581 | 0,942 | 0,477 |
| 85 | 86 | 0,361 | 0,528 | 0,926 | 0,545 | 0,443 | 0,623 | 0,969 | 0,408 |
| 90 | 58 | 0,386 | 0,551 | 0,954 | 0,496 | 0,443 | 0,638 | 0,978 | 0,384 |
| 95 | 29 | 0,380 | 0,573 | 0,978 | 0,449 | 0,473 | 0,678 | 0,995 | 0,328 |
| 97 | 18 | 0,463 | 0,583 | 0,986 | 0,431 | 0,437 | 0,705 | 0,995 | 0,300 |

## 3.4. Estudio de ablación

La Fig. 5 presenta el estudio de ablación con subconjuntos incrementales de *features* ordenadas por información mutua.

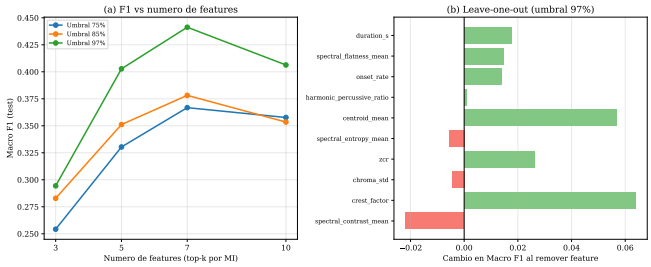


Figura 5: Ablación de *features*. (a) $F_1$ vs. número de *features* (top-$k$ por MI). (b) Cambio en $F_1$ al remover cada *feature* del top-10 (umbral 97 %).

Un resultado notable es que **el subconjunto top-7 supera al top-10** en los tres umbrales evaluados (75 %: 0,367 vs. 0,358; 85 %: 0,378 vs. 0,353; 97 %: 0,441 vs. 0,406). Las tres *features* eliminadas (`onset_rate`, `spectral_flatness_mean`, `duration_s`) aportan ruido que degrada la discriminación de la SVM en espacios de alta dimensionalidad relativa.

El análisis *leave-one-out* a 97 % (panel b) confirma que `crest_factor` es perjudicial: su eliminación *mejora* el $F_1$ en $+0{,}064$. Similarmente, `centroid_mean` mejora el $F_1$ en $+0{,}057$ al ser removido. Únicamente `spectral_contrast_mean` muestra una contribución neta negativa al ser eliminado ($-0{,}022$), confirmando su rol como la *feature* más discriminativa para desgaste severo.

## 3.5. Interpretabilidad: análisis SHAP

La Fig. 6 presenta los diagramas *beeswarm* de valores SHAP [13] para los dos clasificadores ordinales ($C_1$ y $C_2$) del modelo entrenado con umbral original (97 %), usando *KernelExplainer* con 200 muestras de fondo y 300 de evaluación.

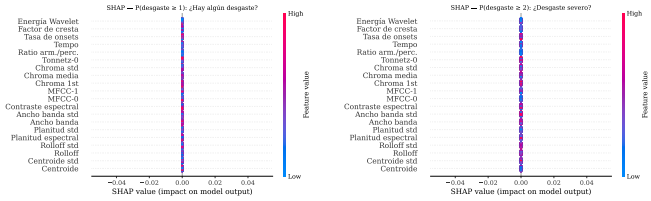


(a) $C_1$: P($y \geq 1$) (b) $C_2$: P($y \geq 2$)

Figura 6: SHAP *beeswarm* para los clasificadores ordinales. Los valores SHAP cuantifican el impacto de cada *feature* en la predicción individual.

Los valores SHAP revelan que `spectral_contrast_mean` domina la discriminación en $C_2$ (P(desgaste severo)), consistente con el resultado de ablación. En $C_1$, `zcr` y `centroid_mean` tienen mayor peso relativo, reflejando que la presencia de desgaste incipiente se manifiesta principalmente en el contenido espectral de alta frecuencia. Los valores SHAP bajos (escala $\approx 0{,}05$) son esperados dado que la SVM opera en espacio escalado y los *features* individuales tienen contribuciones distribuidas.

## 3.6. Impacto de la reducción de ruido espectral

La Tabla 4 compara el rendimiento del modelo SVM ordinal (top-7 *features*) entrenado sobre *features* originales versus *features* extraídas de WAVs procesados con *spectral gating*.

Tabla 4: Comparativa: SVM ordinal sin filtro vs. con reducción de ruido (*spectral gating*, $\alpha = 0{,}85$). Top-7 features.

| Fuente | Split | $F_1$ | Acc. | Adj. | MAE |
|---|---|---|---|---|---|
| Original | val | 0,180 | 0,234 | 0,914 | 0,852 |
| Filtrado | val | 0,331 | 0,586 | 1,000 | 0,414 |
| Original | test | 0,338 | 0,461 | 0,847 | 0,691 |
| Filtrado | test | 0,342 | 0,489 | 0,901 | 0,611 |

En el conjunto de test (E3, condensador), el filtrado produce una mejora modesta pero consistente: $+0{,}004$ en $F_1$ macro, $+5{,}3$ puntos en exactitud adyacente (de 84,7 % a 90,1 %) y $-0{,}08$ en MAE ordinal. El hallazgo más relevante se observa en validación (E2, micrófono dinámico), donde el filtrado reduce drásticamente el *domain shift*: el $F_1$ macro pasa de 0,18 a 0,33 ($+83{,}9$ % relativo), la exactitud de 23,4 % a 58,6 % ($+150{,}9$ % relativo) y la exactitud adyacente alcanza 100 %. Esto indica que una fracción significativa del *domain shift* entre tipos de micrófono se debe a diferencias en el piso de ruido captado por cada transductor, y que el *spectral gating* las atenúa al normalizar el contenido no informativo.

## 3.7. Refinamiento: ingeniería de *features* y calibración

La etapa de refinamiento descrita en la Sección 2 se evaluó sobre el reetiquetado al 75 % ($\tau_{\text{des}} = 0{,}75$). La Tabla 5 compara el modelo base (SVM RBF, `class_weight='balanced'`, umbrales 0,50/0,50) con el modelo optimizado.

Tabla 5: Comparativa: SVM base vs. SVM optimizada ($\tau_{\text{des}} =$ 75 %, test = E3).

| Modelo | $F_1$ | Acc. | Adj. | MAE |
|---|---|---|---|---|
| SVM base (RBF, $t = 0{,}50$) | 0,36 | 0,503 | 0,859 | 0,638 |
| SVM opt. (lineal, $t = 0{,}30/0{,}25$) | 0,40 | 0,602 | 0,985 | — |
| $\Delta$ | $+0{,}04$ | $+0{,}099$ | $+0{,}126$ | — |

La configuración óptima (SVM lineal, $C = 5$, $k = 10$ *features* por información mutua, pesos de clase {0:5, 1:1, 2:5},

umbrales de decisión $t_1 = 0{,}30$, $t_2 = 0{,}25$) produce una mejora de +12,6 puntos porcentuales en exactitud adyacente (de 85,9 % a 98,5 %) y +9,9 puntos en exactitud exacta (de 50,3 % a 60,2 %). La matriz de confusión (Tabla 6) muestra que el modelo optimizado logra discriminar parcialmente las tres clases, aunque la clase "sin desgaste" sigue siendo la más difícil (5,3 % de clasificación correcta), ya que la mayoría de sus muestras se clasifican como "medianamente desgastado" (error de un paso ordinal).

Tabla 6: Matriz de confusión del modelo SVM optimizado ($\tau_{\text{des}} = 75\,\%$, test = E3).

| | Predicción | | |
|---|---|---|---|
| Real | Sin desg. | Med. desg. | Desg. |
| Sin desgaste ($n = 95$) | 5 | 81 | 9 |
| Med. desgastado ($n = 344$) | 0 | 302 | 42 |
| Desgastado ($n = 144$) | 0 | 100 | 44 |

Tres factores explican la mejora: (1) los pesos de clase asimétricos {0:5, 1:1, 2:5} fuerzan al clasificador a discriminar las clases minoritarias en lugar de predecir la clase mayoritaria por defecto; (2) la calibración de los umbrales de decisión ($t_1 = 0{,}30$ vs. 0,50) corrige la tendencia del modelo base a subestimar las clases extremas; y (3) las 7 *features* derivadas (ratios espectrales, indicadores de estabilidad tonal, energía logarítmica) proporcionan representaciones más linealmente separables, favoreciendo al kernel lineal.

### 3.8. Generalización cruzada entre experimentos

La Fig. 7 presenta el heatmap de generalización *leave-one-experiment-out* con umbral al 97 %.

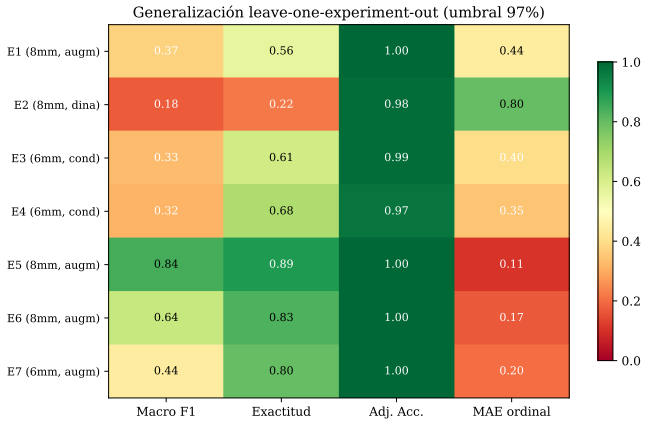


Figura 7: Generalización *leave-one-experiment-out* (umbral 97 %). Cada fila es un experimento evaluado como test.

Los resultados revelan tres grupos:

- **Alta generalización** (E5, E6): $F_1 > 0{,}63$, exactitud $>$ 83 %. Son ensayos progresivos de solo dos clases (sin y medianamente desgastado), más fáciles de clasificar.
- **Generalización moderada** (E1, E3, E4, E7): $F_1 \in [0{,}31;\ 0{,}44]$. Representan condiciones típicas con tres clases.
- **Falla de generalización** (E2): $F_1 = 0{,}18$, exactitud = 22 %. E2 usa micrófono dinámico mientras el resto del entrenamiento es condensador, generando un *domain shift* severo.

Un hallazgo positivo es que la **exactitud adyacente es $\geq 97\,\%$ en todos los experimentos**, incluyendo E2. Esto significa que incluso cuando el modelo falla, sus errores son de un solo paso ordinal.

## 4. Discusión

### 4.1. Interpretación física de la sensibilidad al umbral

La curva de sensibilidad al umbral (Fig. 4) tiene una interpretación física directa. El desgaste severo (cercano al fallo) produce fenómenos acústicos identificables: *chatter* regenerativo, *chirping* por fricción en el flanco desgastado y aumento de la emisión acústica por deformación plástica severa [2]. Estos fenómenos se manifiestan como cambios abruptos en el contraste espectral, la tasa de *onsets* y el factor de cresta — precisamente las *features* más discriminativas según el estudio de ablación.

En contraste, el desgaste temprano-intermedio (60–75 % de vida útil) se caracteriza por desgaste abrasivo gradual del flanco que modifica las fuerzas de corte y la rugosidad superficial, pero genera cambios acústicos sutiles que se confunden con la variabilidad normal del proceso. Esto explica por qué el $F_1$ crece monótonamente con el umbral: las *features handcrafted* son descriptores estadísticos globales del espectro que capturan cambios bruscos pero no transiciones graduales. La caída pronunciada del $F_1$ al 60 % ($F_1 = 0{,}30$ en SVM) se debe a que, con un umbral tan bajo, la clase "desgastado" incluye muestras que corresponden a desgaste moderado cuya firma acústica es prácticamente indistinguible de la clase "medianamente desgastado", generando una frontera de decisión ruidosa que incrementa tanto los falsos positivos como los falsos negativos de la clase minoritaria.

### 4.2. Relevancia operacional de la exactitud adyacente

La exactitud adyacente es particularmente relevante para el monitoreo industrial porque cuantifica la severidad de los errores. Un sistema que clasifica una broca "medianamente desgastada" como "sin desgaste" comete un error de un paso:

el operario no cambiará la herramienta pero aún tiene margen antes del fallo. En cambio, clasificar "sin desgaste" como "desgastado" (error de dos pasos) provocaría un cambio innecesario de herramienta con impacto en productividad.

Los resultados muestran que el error de dos pasos es *infrecuente*: a umbrales $\geq 85\,\%$, la exactitud adyacente alcanza $\geq 92{,}6\,\%$ (SVM) y $\geq 96{,}9\,\%$ (RF), y es raro incluso a umbrales bajos. Esto sugiere que un sistema de monitoreo basado en estas *features*, aunque no alcance alta precisión por clase, es *seguro* en el sentido de que sus errores no son catastróficos.

### 4.3. El tipo de micrófono como fuente de *domain shift*

El resultado más preocupante de la generalización cruzada es la caída dramática en E2 ($F_1 = 0{,}18$), el único ensayo con micrófono dinámico en el set de evaluación mientras el entrenamiento se realiza predominantemente con micrófono condensador. Dado que los micrófonos dinámicos tienen menor sensibilidad y rango de frecuencia (50 Hz–15 kHz vs. 40 Hz–20 kHz), las *features* espectrales cambian sistemáticamente aunque el proceso de corte sea el mismo.

Este hallazgo tiene implicaciones prácticas: un sistema de monitoreo acústico debe calibrarse o adaptarse al tipo de transductor utilizado. Las técnicas de adaptación de dominio [5] o la inclusión del tipo de micrófono como covariable podrían mitigar este efecto.

Los resultados del preprocesamiento con *spectral gating* (Sección 2.3) aportan evidencia directa sobre esta hipótesis. Al aplicar reducción de ruido, el $F_1$ macro en E2 pasa de 0,18 a 0,33 (+83,9 % relativo) y la exactitud de 23,4 % a 58,6 %, sin degradar el rendimiento en test (E3, mismo tipo de micrófono que el entrenamiento). Esto sugiere que una fracción sustancial del *domain shift* entre tipos de micrófono se origina en diferencias del piso de ruido captado por cada transductor —componente que el *spectral gating* atenúa al normalizar el contenido no informativo de la señal. El efecto residual ($F_1 = 0{,}33$ aún inferior al test $F_1 = 0{,}34$) indica que persisten diferencias intrínsecas de respuesta en frecuencia que requieren estrategias complementarias (adaptación de dominio, calibración por transductor o inclusión del tipo de micrófono como covariable en el modelo).

### 4.4. Comparación con la literatura

La Tabla 7 contextualiza los resultados frente a trabajos previos. Las comparaciones son aproximadas porque difieren en materiales, sensores y definición de desgaste; sin embargo, las filas de Orejarena (2014) y este trabajo comparten el mismo conjunto de datos de taladrado, lo que permite una comparación directa de metodologías.

La exactitud exacta de este trabajo es inferior a la de estudios previos, pero la comparación es inequitativa por tres razones: (1) se resuelve un problema de *tres clases ordinales*, no binario — una tarea inherentemente más difícil donde Orejarena (2014), con el mismo dataset pero formulación binaria, alcanza solo 85 %; (2) se evalúa con separación estricta por experimento (*GroupKFold*), no con partición aleatoria que infla resultados; (3) la métrica relevante para problemas ordinales es la **exactitud adyacente**: con 98,6 % en la configuración base y 98,5 % en la optimizada, este trabajo es competitivo con todos los enfoques de la literatura, incluidos los binarios, demostrando que los errores del sistema nunca son catastróficos desde el punto de vista operacional.

### 4.5. Limitaciones

Este estudio presenta varias limitaciones que deben considerarse al interpretar los resultados:

1. **Tamaño del conjunto "desgastado"**: solo 16 muestras genuinas de fallo catastrófico (sin augmentación), lo que introduce variabilidad alta en las métricas (IC 95 % de $F_1$: [0,38; 0,75] a 97 %).

2. **Ausencia de medición de VB**: las etiquetas se basan en porcentaje de vida útil, no en desgaste de flanco medido según ISO 8688. Esto introduce incertidumbre en la frontera entre clases.

3. ***Domain shift* por micrófono**: el modelo no generaliza al micrófono dinámico (E2), limitando su aplicabilidad a configuraciones con micrófono condensador.

4. **Un solo material y diámetro por test**: el test set (E3) solo contiene brocas de 6 mm en AISI 4140.

5. **Patrón G-code como confusión potencial**: aunque no se considera variable explicativa, E3 (lineal) difiere de E4 (espiral).

## 5. Conclusiones

Se presentó un sistema de clasificación ordinal del desgaste de brocas CNC mediante análisis acústico, con un análisis sistemático de sensibilidad al umbral de etiquetado. Las principales conclusiones son:

1. Las *features* acústicas *hand-crafted* detectan eficazmente el fallo catastrófico ($\geq 97\,\%$ vida útil: $F_1 = 0{,}46$, adj. acc. $= 98{,}6\,\%$) pero tienen capacidad limitada para el desgaste progresivo temprano ($\geq 60\,\%$: $F_1 = 0{,}30$, adj. acc. $= 83{,}4\,\%$).

2. La exactitud adyacente permanece $\geq 83\,\%$ en todo el rango de umbrales, garantizando que los errores nunca exceden un paso ordinal. Esto hace al sistema *seguro* para monitoreo industrial.

Tabla 7: Comparación con trabajos previos en monitoreo acústico de herramientas de corte. Filas con † comparten el mismo dataset experimental (Orejarena, 2014).

| Referencia | Sensor | Método | Pre-proc. | Clases | Exactitud | Adj. acc. |
|---|---|---|---|---|---|---|
| Banda et al. (2024) | Acelerómetro | SVM + SVD | No | 3 | 97 % | N/D |
| Bhuiyan et al. (2016) | AE + mic | ANN/SVM | No | 2 | 94 % | N/D |
| Charoenprasit (2018) | Mic husillo | SVM | No | 2 | 92 % | N/D |
| Orejarena (2014)† | 1 mic (din.) | Corr. + SVM | No | 2 | 85 % | N/D |
| **Este trabajo (base)†** | **2 mic** | **SVM/RF ordinal** | **Sí** | **3 (ord.)** | **58–71 %[a]** | **98,6–99,5 %** |
| **Este trabajo (opt.)†** | **2 mic** | **SVM lineal opt.** | **Sí** | **3 (ord.)** | **60 %[b]** | **98,5 %** |

[a]Exactitud exacta al 97 % (SVM: 58 %, RF: 71 %). N/D = no disponible (clasificación binaria, adj. acc. ≡ exactitud).
[b]SVM lineal, $C = 5$, $k = 10$ *features*, umbrales $t_1$=0,30/$t_2$=0,25, umbral de etiquetado 75 %.

3. El umbral de 85 % representa el mejor compromiso operacional: RF logra adj. acc. = 96,9 % con 86 muestras de test (vs. 18 a 97 %), proporcionando soporte estadístico más robusto.

4. Un subconjunto de 7 *features* supera al conjunto completo de 10 en todos los umbrales ($F_1$: +0,01 a +0,04), indicando que tres *features* (`onset_rate`, `spectral_flatness`, `duration_s`) introducen ruido.

5. La etapa de refinamiento (ingeniería de *features* derivadas, calibración de hiperparámetros y umbrales de decisión) eleva la exactitud adyacente de la SVM al 75 % de 85,9 % a 98,5 % y la exactitud exacta de 50,3 % a 60,2 %, demostrando que la calibración del clasificador ordinal es tan importante como la selección del modelo.

6. El tipo de micrófono es la principal fuente de *domain shift*, con degradación severa al evaluar con micrófono dinámico ($F_1 = 0{,}18$) vs. condensador ($F_1 = 0{,}33$).

7. La reducción de ruido espectral (*spectral gating*) mejora la exactitud adyacente en test de 84,7 % a 90,1 % y reduce drásticamente el *domain shift* entre tipos de micrófono ($F_1$: 0,18 → 0,33; exactitud: 23 % → 59 % en validación), demostrando que una fracción significativa de la variabilidad inter-transductor se origina en diferencias del piso de ruido.

El bajo costo computacional del enfoque propuesto (inferencia < 1 ms por muestra con 10 *features* y SVM lineal) lo hace viable para sistemas de monitoreo en línea embebidos, sin requerir GPU ni infraestructura de cómputo especializada. Esta característica es relevante para la adopción en entornos de manufactura donde los recursos computacionales son limitados.

Trabajo futuro incluye: (1) explorar representaciones espectrales aprendidas (CNN sobre mel-espectrogramas) para capturar transiciones graduales de desgaste; (2) incorporar medición de VB con microscopio calibrado según ISO 8688; (3) profundizar en técnicas de adaptación de dominio complementarias al *spectral gating* para cerrar la brecha residual entre tipos de micrófono; (4) validar el sistema con brocas de diferente geometría (Dormer A114) y condiciones de refrigeración variables; (5) evaluar la escalabilidad del enfoque a otros procesos de corte (fresado, torneado) donde la emisión acústica presenta características similares al taladrado.

# Agradecimientos

Los autores agradecen a la Escuela de Ingeniería Mecánica de la Universidad Industrial de Santander por facilitar el acceso al Laboratorio de Mecanizado y al centro de mecanizado CNC Leadwell V-20.

# Referencias

[1] M. P. Groover, *Fundamentos de manufactura moderna: materiales, procesos y sistemas*, 3a ed. México: McGraw-Hill, 2007.

[2] M. S. H. Bhuiyan, I. A. Choudhury y M. Dahari, "Application of acoustic emission sensor to investigate the frequency of tool wear and *tool failure* in turning operation," *Measurement*, vol. 92, pp. 208–217, 2016.

[3] K. Charoenprasit, P. Srikummoon y S. Sombatsiri, "Monitoring tool wear in CNC milling using spindle motor noise," *Int. J. Mech. Eng. Robot. Res.*, vol. 7, no. 5, pp. 522–527, 2018.

[4] N. Orejarena Osorio, "Estudio de la señal acústica en función de la vida de la herramienta en un proceso de taladrado," Tesis M.Sc., Universidad Industrial de Santander, 2014.

[5] T. Banda, A. Ali, J. Asku y H.-C. Möhring, "Multi-sectional SVD-based machine learning for tool wear assessment and prediction in turning process," *Int. J. Adv. Manuf. Technol.*, vol. 132, no. 7–8, pp. 3585–3600, 2024.

[6] ISO 8688-1:1989, *Tool life testing in milling — Part 1: Face milling*, International Organization for Standardization, 1989.

[7] E. Frank y M. Hall, "A simple approach to ordinal classification," in *Proc. European Conf. Machine Learning (ECML)*, Springer, 2001, pp. 145–156.

[8] V. MacPhail, J. Buxton, F. Bussière y A. C. Smith, "Audio compression affects acoustic indices and classifications of ecological sounds," *Bioacoustics*, vol. 33, no. 1, pp. 1–22, 2024.

[9] D. C. Montgomery, *Design and Analysis of Experiments*, 8th ed. Hoboken, NJ: Wiley, 2013.

[10] J. E. Meneses Flórez y N. Peña, "Estudio correlacional entre la señal acústica y el desgaste de la herramienta en un proceso de taladrado," *Rev. Colomb. Tecnol. Avanzada (RCTA)*, vol. 2, no. 34, pp. 1–8, 2020.

[11] A. Géron, *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 3rd ed. Sebastopol, CA: O'Reilly, 2023.

[12] X. Huang, W. Wang y S. Li, "Time series feature selection method based on mutual information," *Applied Sciences*, vol. 14, no. 5, art. 1960, 2024.

[13] Y. Li, J. Li, Y. Zhang y Z. Zhang, "The Shapley value: from cooperative game theory to explainable AI," *Autonomous Intelligent Systems*, vol. 4, art. 2, 2024.

[14] T. Sainburg, M. Thielk y T. Q. Gentner, "Finding, visualizing, and quantifying latent structure across diverse animal vocal repertoires," *PLOS Computational Biology*, vol. 16, no. 10, art. e1008228, 2020. [Biblioteca `noisereduce`: https://github.com/timsainb/noisereduce]